

Introduction to RAG (Retrieval–Augmented Generation)

مؤنشر، منبع، Agency

LLM مخفف Large Language Model یا «مدل زبانی بزرگ» است؛
نوعی مدل هوش مصنوعی که با آموزش روی حجم عظیمی از داده‌های
متنی، می‌تواند زبان انسان را پردازش کند و متن تولید کند.

تعداد پارامتر

۸۰ B

۱۲۰ B


۲۴۰ B


language model → Large

مقدار داده‌های آموزشی!

Astra → ✓
Sol

Gen AI
→ Text
→ Voice
→ Image / Video
→ Tabular data!







محدودیت های چت بات ها

توهم (Hallucination)

صفا ارزشی ندارد!

خوشتر دروغ را گویند!

همه مردم سیرقند را

توهم، توهم، توهم
دروغ را گویند!

Hallucination


عبرانی توهم!

Astra

تولید پاسخ‌هایی که از نظر دستوری و ظاهری بسیار مطمئن و متقاعدکننده هستند، اما از نظر محتوایی کاملاً نادرست یا ساختگی اند.

61
Hollin

توهم توهم
توهم توهم



دانش منجمد (Knowledge Cutoff)

اطلاعات مدل محدود به تاریخ پایان آموزش آن است و از اتفاقات، اخبار و داده‌های پس از آن زمان کاملاً بی‌خبر است.





نبود دانش خصوصی / سازمانی

مدل‌های عمومی هیچ دسترسی به مستندات داخلی، قوانین و آیین‌نامه‌های شرکت، فایل‌های PDF سازمانی یا داده‌های محرمانه ندارند.

در زمان از دست رفتن پرسنل
تغییرات کمتر بودن را
Dot in :

chatgpt / Hallucination

نظم / قطع

HR:

Un General.

ترجمه

medical:

نورهای بزرگ!

دانش ضعیف در موضوعات تخصصی

در حوزه‌های حقوقی، پزشکی تخصصی یا زبان‌های کم‌منبع، دقت چت‌بات خام به شدت افت می‌کند.

و / حقوق / زبان

Gemma → Gen!

Med Gemma → medical

LLM / chat bot

HR: ترجمه

ترجمه

claude
Gemini
Gpt
⋮

item
میزان توکن ورودی → content window.

gpt : 100k token.

آشنا → 3000 page!

محدودیت پنجره زمینه (Context Window)

نمی توان تمام مستندات و کتاب های یک سازمان را یک جا درون پرامپت ورودی جای داد.


upload → gpt plus
تواریخ برسد!

docx
word

امنیت و سطح دسترسی

هر کاربر نباید به تمام داده‌ها دسترسی داشته باشد. کنترل دسترسی مستقیم روی پرامپت LLM بسیار دشوار است.


راهکارهای موجود



✓ پرامپت نویسی (Prompting)


② - My Question + Document! → llm → ✓

راهکارهای موجود




راهکارهای موجود

prompt + document!



قرار دادن کل سند در پرامپت

راهکارهای موجود




content window
limitation.

قرار دادن کل سند در پرامپت

✓ مزایا: بدون نیاز به ساخت پایگاه داده

✗ معایب / محدودیت: محدودیت حجم، هزینه بالا و کندگی شدید

راهکارهای موجود



راهکارهای موجود

Res. $\rightarrow$ ~~8~~

Qwen 3.5

8 — 4700

100/8.43

Fine-tuning

blm → Tent

→ classificat

✓ مزایا: عالی برای یادگیری سبک و لحن

✗ معایب / محدودیت: نامناسب برای دانش متغیر، گران، عدم حذف توهم

General $\rightarrow$ PR.

راهکارهای موجود

معماری RAG

راهکارهای موجود


معماری RAG

✓ مزایا: دانش به روز، دقیق و قابل ارجاع ✎

✗ معایب / محدودیت: نیاز به زیرساخت پایگاه برداری و بازیابی

✎

RAG




md

meeting
report.md


اینگیزین

KB!


Storing your data on Vector Database: 1. Document Loading




Storing your data on Vector Database: 2. Document Splitting




Storing your data on Vector Database: 3. Embedding



Storing your data on Vector Database: 3. Embedding




Example: embed query




- Embedding translates each of the split text “chunks” into a high-dimensional numerical representation.
- Goal is to preserve the semantic and contextual similarities and differences.

Storing your data on Vector Database: 4. Vectorstoring



نحوه تعامل LLM و RAG

Basic RAG Pipeline




فانتزی در باب نور باران در ه

فانتزی در باب نور باران

Embedding و جستجوی معنایی

جستجوی کلیدواژه‌ای و معنایی

جستجوی کلیدواژه‌ای فقط کلمات دقیق را تطبیق می‌دهد؛ اما جستجوی معنایی مفهوم پشت جملات را (مثل مترادف‌ها) کاملاً درک می‌کند.



user prompt

[از 1, 2, 3, 4]

vector DB

1 Semantic Search

2 Similarity Search

3

Hybrid Search

top-k

محاسبه معنایی

فانتزی در باب نور باران

Semantic

Embedding و جستجوی معنایی

بردارهای معنایی (Embeddings)

تبدیل کلمات و جملات به بردارهای عددی چندبعدی تا متن‌های دارای مفهوم مشابه، بردارهای نزدیک به هم دریافت کنند.

Embedding و جستجوی معنایی

$$\text{cosine similarity} = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$

user prompt $\vec{A}$ chunk $\vec{B}$


semantic
search!

$$0 \leq \cos \theta < 1$$

معیارهای شباهت (Similarity Metrics)

استفاده از Cosine Similarity (زاویه بین بردارها) و Dot Product برای محاسبه میزان شباهت معنایی دو متن.

Embedding و جستجوی معنایی



KB → Tabular



vectorized

Embedding

CWD

chat with data

Text to SQL
Text to Pandas

System prompt

این جدول در باره مرغ ها می باشد

سوزن نام ها و فواید آن ها، میزان فواید این ها را بگو، آیا مرغ ها می توانند ... را در دست بگیرند؟

میتواند در دست بگیرد یا نه؟

Wolf

Dog

Cat

Query: Kitten

Banana

Apple


آقای عزیز من در یک نام و در سوزن ها

NER → فرارسی
نام / نام خانوادگی

پایگاه داده برداری (Vector DB)

چرا پایگاه برداری؟

دیتابیس‌های سنتی برای مقایسه بردارهای چند صد بعدی مناسب نیستند. دیتابیس برداری جستجوی میلیون‌ها بردار را در میلی‌ثانیه ممکن می‌کند.



ابزارهای محبوب
معرفی ابزارهای FAISS (محیط محلی / سریع)، Chroma (ساده و آموزشی)، Qdrant و Milvus (سازمانی) و pgvector.

جلسه ۷: بازیابی (Retrieval)

جستجوی Top-k

تولید پاسخ (Generation)

طراحی پرامپت RAG

تزریق زمینه (Context) بازیابی شده در پرامپت سیستم و هدایت مدل برای پاسخ دقیق بر اساس متن.

کنترل توهم (Hallucination Control)

دستور صریح به مدل: «فقط از متن زیر پاسخ بده؛ اگر پاسخ نیست بگو نمی دانم».

system prompt


α [$\leftarrow$]

α [user prompt
+ top k chunks!]

ارجاع دهی (Citation)


الزام مدل به ذکر شماره سند یا صفحه مربوطه در انتهای پاسخ جهت راستی آزمایی توسط کاربر.

RETRIEVAL-AUGMENTED GENERATION (RAG) WORKFLOW





The End


Simple RAG Implementation



Basic RAG Pipeline



Basic RAG Pipeline



Step 1: Data Indexing

Step 2: Data Retrieval & Generation

